

RAG hybride pour l’analyse de rapports financiers 10-K (GAFAM)

Système de question-réponse ancré dans des filings SEC — retrieval hybride texte + roadmap données tabulaires (text-to-SQL) et routing intelligent.

Auteur : Sara El Harti **Profil :** Master 1 Data Science × Financial Engineering **Type :** projet personnel d’ingénierie RAG de bout en bout
Corpus : 5 Form 10-K (Apple, Amazon, Alphabet, Meta, Microsoft)

Problématique & objectif

Les rapports 10-K mêlent narratif dense (facteurs de risque, MD&A) et états financiers chiffrés. Un LLM seul hallucine ; une recherche purement lexicale rate les paraphrases. Ce projet construit un **RAG (Retrieval-Augmented Generation)** qui récupère les passages pertinents puis génère une réponse *citée*, avec une architecture évolutive vers l’interrogation SQL des tableaux.

Architecture produit (3 versions)

V1 livrée RAG texte Pipeline complet : extraction PDF → chunking → embeddings → Qdrant → recherche hybride (dense + BM25, fusion RRF) → rerank optionnel → génération locale (Ollama) → UI Streamlit → évaluation RAGAS.	V2 Module tabulaire Données financières structurées dans DuckDB ; questions chiffrées via text-to-SQL (sans routing auto). Complète le RAG là où les tableaux cassent le chunking texte.
V3 Orchestration Function calling : le système choisit texte, SQL, ou les deux, puis fusionne les réponses. Un seul point d’entrée pour l’analyste.	Valeur pour un recruteur Maîtrise NLP/LLM appliquée à la finance, retrieval moderne, eval, produit démo, et vision claire données non structurées ↔ structurées.

V1 — pipeline technique (réalisé)

1. Extraction Docling : PDF 10-K → Markdown structuré (titres, blocs).	2. Chunking Hybride : coupe sur titres Markdown, puis taille max + overlap.	3. Index Embeddings BGE-small (384-d) ; Qdrant local (cosine) + meta entreprise/section.	4. Réponse Hybride RRF ± rerank MiniLM ; Ollama qwen2.5:3b ; démo Streamlit ; RAGAS.
--	---	--	--

Choix clés : recherche hybride pour corriger les faux amis sémantiques (ex. « supply agreements » vs risques supply chain) ; génération locale pour un déploiement sans coût API ; filtre par ticker/entreprise pour limiter le bruit cross-GAFAM. **Échelle indicative V1 :** ~2 200 chunks indexés sur 5 filings.

Stack & livrables

Stack : Python · Docling · sentence-transformers (BGE) · Qdrant · rank-bm25 · Ollama · Streamlit · RAGAS · (Claude API optionnelle) · DuckDB prévue en V2 | **Livrables :** code modulaire (extraction, chunking, embeddings, indexing, retrieval, generation, evaluation) · interface démo · dataset d’éval · one-pager

Limites assumées & apprentissages

- Tableaux financiers fragiles en V1 texte → motivent explicitement la V2 SQL.
- Reranker léger (MiniLM) parfois inférieur à l’hybride RRF seul — d’où l’intérêt de mesurer (RAGAS).
- Juge RAGAS local (petit LLM) : scores indicatifs, utiles pour itérer, pas comme benchmark labo.